

Projet en statistique non-paramétrique

Année universitaire 2019-2020

- Le projet peut se faire par binôme ou tout seul.
- Le projet doit se nommer `nomprenom1-nomprenom2.pdf`
- Les insctructions du logiciel R et les programmes doivent être joints au rapport
- Le projet doit être envoyé, au plutard le 15 Décembre 2019, à l'adresse suivante: `sana.louhichi@univ-grenoble-alpes.fr`

On considère le modèle de régression,

$$Y_i = g\left(\frac{i}{n}\right) + \epsilon_i, \quad 1 \leq i \leq n.$$

On suppose ici $\epsilon_1, \dots, \epsilon_n$ des variables aléatoires centrées et de variance σ^2 et dépendantes. Elles vérifient la relation,

$$\epsilon_n = \eta_n \sqrt{\sigma^2(1 - \alpha) + \alpha \epsilon_{n-1}^2}, \quad 0 \leq \alpha < 1, \quad (1)$$

avec $(\eta_n)_{n \geq 1}$ est une suite iid centrée de loi normal $\mathcal{N}(0, 1)$ et η_n est indépendante de $(\epsilon_1, \dots, \epsilon_{n-1})$.

On définit, \hat{g} l'estimateur de g , par

$$\hat{g}(x) = \frac{1}{nh} \sum_{i=1}^n Y_i K\left(\frac{x - X_i}{h}\right).$$

h est la fenêtre et K est un noyau pair et à support compact. L'objectif de ce projet est d'étudier empiriquement un bon choix de la fenêtre h . On prendra par la suite que

$$g(x) = \sin(2\pi x).$$

1. Représenter sur un même graphique le nuage des points $(\frac{i}{n}, Y_i)_{1 \leq i \leq n}$, la fonction g et l'estimateur \hat{g} pour un choix de K , de α et de σ^2 que vous préciserez.
2. Visualisez, selon des différentes valeurs de h , la situation de sous et de sur-lissage.
3. Écrire un programme qui calcule la valeur optimale du paramètre de lissage en fonction du ASE (*Average square error*) qui est définit par,

$$ASE(h) = \frac{1}{n} \sum_{i=1}^n (\hat{r}(x_i) - r(x_i))^2.$$

Soit \hat{h}_0 cette valeur optimale du $ASE(h)$, c'est-à-dire,

$$\hat{h}_0 = \operatorname{argmin}_{h>0} ASE(h).$$

4. Même question, en remplaçant $ASE(h)$ pour le critère de validation croisé $CV(h)$, définit comme suit,

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \left(\frac{\hat{r}(x_i) - Y_i}{1 - L_{i,i}} \right)^2$$

avec $L_{i,i} = \frac{K(0)}{nh}$. On pose,

$$\hat{h} = \operatorname{argmin}_{h>0} CV(h).$$

5. Illustrer le comportement asymptotique lorsque n tend vers l'infini de $\frac{ASE(\hat{h})}{ASE(\hat{h}_0)}$. Conclure.
6. Illustrer le comportement asymptotique lorsque n tend vers l'infini de $\frac{\hat{h}}{\hat{h}_0}$. Conclure.
7. Vérifier, par simulations, que $n^{3/10}(\hat{h} - \hat{h}_0)$ a un comportement gaussien.
8. Que peut être la loi asymptotique de $n \left(ASE(\hat{h}) - ASE(\hat{h}_0) \right)$.
9. Conclure quant au critère $CV(h)$.