

Méthodes de Monte Carlo

Master parcours SSD - UE Statistique Computationnelle

Septembre 2019

- ▶ Diverses définitions proposées pour caractériser une méthode de Monte Carlo.
- ▶ Nous prendrons celle donnée dans Rizzo (2007, §6.1) :
"toute méthode d'inférence statistique ou d'analyse numérique s'appuyant sur des techniques de simulation [de variables aléatoires]".
- ▶ Nous nous intéresserons donc à ces deux types d'applications :
 - ▶ l'analyse numérique et la problème de l'intégration.
 - ▶ l'inférence statistique pour la caractérisation d'un estimateur ou des performances d'un test statistique.
- ▶ Mais avant cela, nous allons nous intéresser à la simulation de variables aléatoires

Simulation de variables aléatoires

- ▶ Simuler des variables selon une **loi uniforme** est un problème bien connu.
- ▶ Le logiciel R permet de simuler selon les **lois usuelles**.
 - ▶ uniforme, normale, Poisson, χ^2 , binomiale, ...
- ▶ La simulation d'autres lois peut être plus complexe.
- ▶ Nous allons illustrer deux méthodes de simulation :
 - ▶ **l'inversion de la fonction de répartition**,
 - ▶ **l'algorithme du rejet**.

- ▶ La base : la loi normale (centrée réduite)
 - ▶ **dnorm** : fonction densité ($\text{dnorm}(0) = 1/\sqrt{2\pi}$)
 - ▶ **pnorm** : fonction de répartition ($\text{pnorm}(0) = 0.5$)
 - ▶ **qnorm** : quantiles ($\text{qnorm}(0.5) = 0$)
 - ▶ **rnorm** : génération de nombres aléatoires

- ▶ La base : la loi normale (centrée réduite)
 - ▶ `dnorm` : fonction densité ($\text{dnorm}(0) = 1/\sqrt{2\pi}$)
 - ▶ `pnorm` : fonction de répartition ($\text{pnorm}(0) = 0.5$)
 - ▶ `qnorm` : quantiles ($\text{qnorm}(0.5) = 0$)
 - ▶ `rnorm` : génération de nombres aléatoires
- ▶ Pour les autres lois, remplacer norm par un autre suffixe
 - ▶ `dunif`, `punif`, `qunif`, `runif` pour la loi uniforme
 - ▶ `dexp`, `pexp`, `qexp`, `rexp` pour la loi exponentielle

- ▶ La base : la **loi normale** (centrée réduite)
 - ▶ **dnorm** : fonction densité ($\text{dnorm}(0) = 1/\sqrt{2\pi}$)
 - ▶ **pnorm** : fonction de répartition ($\text{pnorm}(0) = 0.5$)
 - ▶ **qnorm** : quantiles ($\text{qnorm}(0.5) = 0$)
 - ▶ **rnorm** : génération de nombres aléatoires
- ▶ Pour les autres lois, remplacer norm par un autre suffixe
 - ▶ **dunif**, **punif**, **qunif**, **runif** pour la **loi uniforme**
 - ▶ **dexp**, **pexp**, **qexp**, **rexp** pour la loi **exponentielle**
- ▶ Pour visualiser une **distribution empirique**
 - ▶ la fonction **hist** calcule et/ou affiche l'histogramme
 - ▶ la fonction **density** calcule la densité par la **méthode des noyaux** (**plot.density** pour la visualiser)

?distributions() : densités disponibles en R

Details

The functions for the density/mass function, cumulative distribution function, quantile function and random variate generation are `qxxx` and `rxxx` respectively.

For the beta distribution see `dbeta`.

For the binomial (including Bernoulli) distribution see `dbinom`.

For the Cauchy distribution see `dcauchy`.

For the chi-squared distribution see `dchisq`.

For the exponential distribution see `dexp`.

For the F distribution see `df`.

For the gamma distribution see `dgamma`.

For the geometric distribution see `dgeom`. (This is also a special case of the negative binomial.)

For the hypergeometric distribution see `dhyper`.

For the log-normal distribution see `dlnorm`.

For the multinomial distribution see `dmultinom`.

For the negative binomial distribution see `dnbinom`.

For the normal distribution see `dnorm`.

For the Poisson distribution see `dpois`.

For the Student's t distribution see `dt`.

For the uniform distribution see `dunif`.


For the Weibull distribution see `dweibull`.

For less common distributions of test statistics see `pbirthday`, `dsignrank`, `ptukey` and `dwilcox` (and see the 'See Also' section of

Simulation de lois usuelles avec R


► Exemple :

```
> n = 1000      # nombre d'échantillons  
> x = rnorm(n)  # tirage selon la loi N(0,1)  
> plot(density(x), main = "")  
> title("loi normale & densité empirique")  
> rug(x)
```



(Rappel : estimation par noyau - principe)

Principe :



- ▶ on positionne un "noyau" sur chaque observation
- ▶ on les **moyenne** pour estimer la densité

⇒ méthode de Parzen : Kernel Density Estimation

(Rappel : estimation par noyau - définition)

Formellement, à partir de l'échantillon (x_1, \dots, x_n) :

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n K(x - x_i), \quad \forall x \in \mathcal{X}$$

où $K(\cdot)$ est un **noyau** = une fonction :

- ▶ non-négative
- ▶ dont l'intégrale vaut 1
- ▶ qui est centrée sur zéro

(Rappel : estimation par noyau - définition)

Formellement, à partir de l'échantillon (x_1, \dots, x_n) :

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n K(x - x_i), \quad \forall x \in \mathcal{X}$$

où $K(\cdot)$ est un **noyau** = une fonction :

- ▶ non-négative
- ▶ dont l'intégrale vaut 1
- ▶ qui est centrée sur zéro

⇒ **Intuitivement** : une moyenne locale, avec une notion de proximité définie par K .

(Rappel : estimation par noyau - définition)

Formellement, à partir de l'échantillon (x_1, \dots, x_n) :

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n K(x - x_i), \quad \forall x \in \mathcal{X}$$

où $K(\cdot)$ est un **noyau** = une fonction :

- ▶ non-négative
- ▶ dont l'intégrale vaut 1
- ▶ qui est centrée sur zéro

⇒ **Intuitivement** : une moyenne locale, avec une notion de proximité définie par K .

Noyau typique = Gaussien : $K(x) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{1}{2}x^2)$.

(Rappel : estimation par noyau - fonction noyau)

Noyaux classiques :

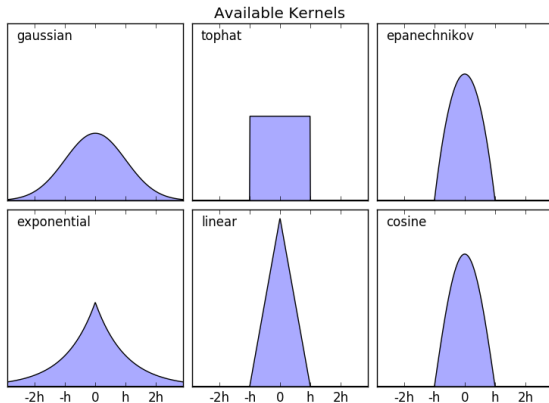


Figure: Noyaux disponibles dans Scikit-Learn (et R).

(Rappel : estimation par noyau - fonction noyau)

Une question clé : le choix de la **largeur de bande**

$$\hat{f}(x) = \frac{1}{n} \sum_i K(x - x_i) \Rightarrow \hat{f}_h(x) = \frac{1}{nh} \sum_i K\left(\frac{x - x_i}{h}\right)$$




Figure: réalité, $h=2$, $h=0.05$, $h=0.337$

Simulation de variables aléatoires par inversion

Principe :

- ▶ S'appuyer sur la distribution cumulée F pour simuler selon f .
- ▶ En effet : $\text{si } U \rightarrow \mathcal{U}(0, 1) \text{ alors } F^{-1}(U) \rightarrow f$.


Simulation de variables aléatoires par inversion

Principe :

- ▶ S'appuyer sur la distribution cumulée F pour simuler selon f .
- ▶ En effet : $\boxed{\text{si } U \rightarrow \mathcal{U}(0, 1) \text{ alors } F^{-1}(U) \rightarrow f}$.

Illustration :

- ▶ **En rouge** = densité cible ; **en bleu** = distribution cumulée.
- ▶ 1) On tire u uniformément sur $[0, 1]$.
- ▶ 2) On prend x^* tel que $F(x^*) = u$.



⇒ On tire u selon l'axe des ordonnées.

⇒ La probabilité de tirer x est faible dans les zones où $F(x)$ est plate.

Simulation de variables aléatoires par inversion

Hypothèses de travail :

- ▶ on connaît la forme analytique de f
- ▶ (on sait simuler selon $\mathcal{U}(0, 1)$)

Simulation de variables aléatoires par inversion

Hypothèses de travail :

- ▶ on connaît la forme analytique de f
- ▶ (on sait simuler selon $\mathcal{U}(0, 1)$)

Procédure :

1. calculer la fonction de repartition $F(x)$
2. calculer sa fonction réciproque $F^{-1}(u)$
 - ▶ poser $u = F(x)$
 - ▶ résoudre l'équation en x pour trouver $x = F^{-1}(u)$
3. tirer (u_1, \dots, u_n) selon $\mathcal{U}(0, 1)$
4. calculer $x_i = F^{-1}(u_i)$, pour $i = 1, \dots, n$.

Simulation de variables aléatoires par rejet

Principe :

- ▶ On choisit 1) une densité auxiliaire g selon laquelle on sait simuler, et 2) $k \in \mathbb{R}$ tel que $f(x) \leq kg(x), \forall x$.


Simulation de variables aléatoires par rejet

Principe :

- ▶ On choisit 1) une densité auxiliaire g selon laquelle on sait simuler, et 2) $k \in \mathbb{R}$ tel que $f(x) \leq kg(x), \forall x$.

Illustration :

- ▶ **En rouge** = densité f ; **en bleu** = "densité" majorante kg .
- ▶ 1) On tire x_0 selon g .
- ▶ 2) On tire u_0 uniformément dans $[0; kg(x_0)]$.
- ▶ 3) Si $u_0 \leq f(x_0)$ on garde x_0 , sinon on le rejette.



\Rightarrow La probabilité de tirer x dépend de l'écart entre $f(x)$ et $kg(x)$.

\Rightarrow Le taux de rejet augmente en fonction de l'aire grise.

Simulation de variables aléatoires par rejet

Hypothèses de travail :

- ▶ on connaît la forme analytique de f
- ▶ on connaît k et g tels que $f(x) \leq kg(x), \forall x$
- ▶ on sait simuler selon g (et selon $\mathcal{U}(0, 1)$)

Simulation de variables aléatoires par rejet

Hypothèses de travail :

- ▶ on connaît la forme analytique de f
- ▶ on connaît k et g tels que $f(x) \leq kg(x), \forall x$
- ▶ on sait simuler selon g (et selon $\mathcal{U}(0, 1)$)

Procédure :

1. tirer x_i selon g , pour $i = 1, \dots, n$
2. tirer u_i selon $\mathcal{U}(0, kg(x_i))$
3. conserver x_i si $u_i \leq f(x_i)$

Simulation de variables aléatoires par rejet

Hypothèses de travail :

- ▶ on connaît la forme analytique de f
- ▶ on connaît k et g tels que $f(x) \leq kg(x), \forall x$
- ▶ on sait simuler selon g (et selon $\mathcal{U}(0, 1)$)

Procédure :

1. tirer x_i selon g , pour $i = 1, \dots, n$
2. tirer u_i selon $\mathcal{U}(0, kg(x_i))$
3. conserver x_i si $u_i \leq f(x_i)$

En pratique :

- ▶ on applique cette procédure jusqu'à obtenir le nombre de tirages voulu (e.g., avec une boucle "tant que").
- ▶ le **taux de rejet** quantifie l'efficacité de la procédure.


Simulation par inversion :

- ▶ + : simple
- ▶ - : on ne sait pas toujours calculer F^{-1}

Simulation par rejet :

- ▶ + : plus générique
- ▶ - : difficile de choisir la densité majorante

⇒ extension : méthode du **rejet adaptatif**



⇒ les tirages rejetés servent
à définir une enveloppe
autour de f .

Figure: Image tirée de Bishop (2006).

Et la loi uniforme dans tout ça ?

La **loi uniforme** est à la base de nombreux simulateurs.

- ▶ via les méthodes d'inversion et de rejet en particulier

Un **problème bien connu**...mais pas si trivial.

Et la loi uniforme dans tout ça ?

La **loi uniforme** est à la base de nombreux simulateurs.

- ▶ via les méthodes d'inversion et de rejet en particulier

Un **problème bien connu**...mais pas si trivial.

Méthode classique = **générateur congruentiel** :

$$x_n = \frac{z_n}{m}, \text{ avec } z_n = (az_{n-1} + b)(\text{modulo } m)$$

Et la loi uniforme dans tout ça ?

La **loi uniforme** est à la base de nombreux simulateurs.

- ▶ via les méthodes d'inversion et de rejet en particulier

Un **problème bien connu**...mais pas si trivial.

Méthode classique = **générateur congruentiel** :

$$x_n = \frac{z_n}{m}, \text{ avec } z_n = (az_{n-1} + b)(\text{modulo } m)$$

⇒ génère une **suite** de nombres aléatoires x_i .

Et la loi uniforme dans tout ça ?

La **loi uniforme** est à la base de nombreux simulateurs.

- ▶ via les méthodes d'inversion et de rejet en particulier

Un **problème bien connu**...mais pas si trivial.

Méthode classique = **générateur congruentiel** :

$$x_n = \frac{z_n}{m}, \text{ avec } z_n = (az_{n-1} + b)(\text{modulo } m)$$

⇒ génère une **suite** de nombres aléatoires x_i .

⇒ à (a, b, m) fixés, la suite est **déterminée par z_0** .

- ▶ z_0 est la **graine** (seed) du générateur.

Et la loi uniforme dans tout ça ?

La **loi uniforme** est à la base de nombreux simulateurs.

- ▶ via les méthodes d'inversion et de rejet en particulier

Un **problème bien connu**...mais pas si trivial.

Méthode classique = **générateur congruentiel** :

$$x_n = \frac{z_n}{m}, \text{ avec } z_n = (az_{n-1} + b)(\text{modulo } m)$$

⇒ génère une **suite** de nombres aléatoires x_i .

⇒ à (a, b, m) fixés, la suite est **déterminée par z_0** .

- ▶ z_0 est la **graine** (seed) du générateur.

⇒ c'est en réalité une suite de **nombres pseudo-aléatoires**.

- ▶ on peut donc la répéter en fixant la graine.

Simulation de la loi Uniforme

Méthode du **générateur congruentiel** :

$$x_n = \frac{z_n}{m}, \text{ avec } z_n = (az_{n-1} + b)(\text{modulo } m)$$

⇒ génère une **suite** de nombres **pseudo-aléatoires**

Simulation de la loi Uniforme

Méthode du **générateur congruentiel** :

$$x_n = \frac{z_n}{m}, \text{ avec } z_n = (az_{n-1} + b)(\text{modulo } m)$$

⇒ génère une **suite** de nombres **pseudo-aléatoires**

- ▶ z_0 = graine (fixée); x_n : n -ième valeur obtenue.
- ▶ $z = y(\text{modulo } m)$: le reste de $y/m \rightarrow \in [0, \dots, m-1]$
- ▶ $x = z/m$: ramène z entre 0 et 1.
- ▶ $m \sim$ le nombre de valeurs distinctes possibles.
 - ▶ à prendre le + grand possible (e.g., $2^{31} - 1$, 10^8).
- ▶ a, b : à choisir avec soin pour avoir une bonne suite!

Introduction

Simulation de
variables
aléatoires

Introduction

Inversion

Rejet

Loi uniforme

Méthodes MC
pour l'intégration

Pour aller plus
loin : réduction
de variance

Références

Simulation de la loi Uniforme

Méthode du **générateur congruentiel** :

$$x_n = \frac{z_n}{m}, \text{ avec } z_n = (az_{n-1} + b)(\text{modulo } m)$$

⇒ génère une **suite** de nombres **pseudo-aléatoires**

- ▶ z_0 = graine (fixée) ; x_n : n -ième valeur obtenue.
- ▶ $z = y(\text{modulo } m)$: le reste de $y/m \rightarrow \in [0, \dots, m-1]$
- ▶ $x = z/m$: ramène z entre 0 et 1.
- ▶ $m \sim$ le nombre de valeurs distinctes possibles.
 - ▶ à prendre le + grand possible (e.g., $2^{31} - 1$, 10^8).
- ▶ a, b : à choisir avec soin pour avoir une bonne suite !

⇒ voir **?RNG** pour la mise en oeuvre R.

⇒ en pratique, utiliser **set.seed()** pour **fixer la graine**.

- ▶ et donc garantir que le script est reproductible.

Introduction

Simulation de
variables
aléatoires

Introduction

Inversion

Rejet

Loi uniforme

Méthodes MC
pour l'intégration

Pour aller plus
loin : réduction
de variance

Références

Méthodes Monte-Carlo pour l'intégration

- ▶ La question de **l'intégration est au cœur de nombreux domaines** : physique, finance, biologie...et statistiques.
 - ▶ voir 2ème partie du cours sur les approches Bayésiennes
- ▶ **Parfois complexe à résoudre** :
 - ▶ nombreuses variables couplées par des modèles complexes
 - ▶ primitives difficiles à déterminer
 - ▶ primitives trop longues à résoudre par des techniques d'analyse numérique
- ▶ L'approche MC s'appuie sur des méthodes de **simulation de variables aléatoires** pour **approximer une intégrale**.

- ▶ La question de **l'intégration est au cœur de nombreux domaines** : physique, finance, biologie...et statistiques.
 - ▶ voir 2ème partie du cours sur les approches Bayésiennes
- ▶ **Parfois complexe à résoudre** :
 - ▶ nombreuses variables couplées par des modèles complexes
 - ▶ primitives difficiles à déterminer
 - ▶ primitives trop longues à résoudre par des techniques d'analyse numérique
- ▶ L'approche MC s'appuie sur des méthodes de **simulation de variables aléatoires** pour **approximer une intégrale**.


⇒ une approche **stochastique** pour un problème **déterministe**.

⇒ approximation = **réponse statistique** du type *"la valeur recherchée se trouve très probablement dans cet intervalle"*.

Exemples introductifs¹

Approximation de la superficie d'un lac :


- ▶ une armée tire X boulets de canon sur un terrain de taille S .
- ▶ On compte ensuite le nombre N de boulets restés sur le terrain.



Exemples introductifs¹

Approximation de la superficie d'un lac :

- ▶ une armée tire X boulets de canon sur un terrain de taille S .
- ▶ On compte ensuite le nombre N de boulets restés sur le terrain.




⇒ l'aire du lac peut être approximée comme $S \times \frac{X-N}{X}$.

Exemples introductifs¹

Approximation de la superficie d'un lac :

- ▶ une armée tire X boulets de canon sur un terrain de taille S .
- ▶ On compte ensuite le nombre N de boulets restés sur le terrain.




⇒ l'aire du lac peut être approximée comme $S \times \frac{X-N}{X}$.

⇒ sous quelle(s) hypothèse(s) est-ce valide ?

Approximation de π :

- ▶ on tire aléatoirement (et uniformément) des points (x, y) dans $[0, 1] \times [0, 1]$.
- ▶ La proportion de points tels que $x^2 + y^2 \leq 1$ est une approximation de $\pi/4$.



Description de la méthode

- ▶ On cherche à calculer

$$I = \int_0^1 g(x)dx.$$

- ▶ Principe Monte-Carlo : écrire I comme une espérance.

Description de la méthode

- ▶ On cherche à calculer

$$I = \int_0^1 g(x)dx.$$

- ▶ Principe Monte-Carlo : écrire I comme une espérance.
- ▶ Rappelons que si X est une variable aléatoire de densité f , alors par définition :

$$E[X] = \int_{-\infty}^{+\infty} xf(x)dx.$$

Description de la méthode

- ▶ On cherche à calculer

$$I = \int_0^1 g(x)dx.$$

- ▶ Principe Monte-Carlo : écrire I comme une espérance.
- ▶ Rappelons que si X est une variable aléatoire de densité f , alors par définition :

$$E[X] = \int_{-\infty}^{+\infty} xf(x)dx.$$

- ▶ Par ailleurs, pour toute fonction $g : \mathbb{R} \rightarrow \mathbb{R}$, $g(X)$ est une variable aléatoire d'espérance :

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x)f(x)dx.$$

Description de la méthode

- On cherche donc à calculer

$$I = \int_0^1 g(x) dx,$$

en l'écrivant comme

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x)f(x)dx,$$

où f est une densité de probabilité.

Description de la méthode

- On cherche donc à calculer

$$I = \int_0^1 g(x) dx,$$

en l'écrivant comme

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x)f(x)dx,$$

où f est une densité de probabilité.

- Il suffit de considérer que X suit une **loi uniforme** sur $[0, 1]$, sa densité étant définie comme :

$$f(x) = \begin{cases} 1 & \text{si } 0 \leq x \leq 1 \\ 0 & \text{sinon.} \end{cases}$$

Description de la méthode

- On cherche donc à calculer

$$I = \int_0^1 g(x) dx$$

- On l'écrit comme $I = E[g(X)]$: l'espérance de la variable aléatoire $g(X)$, où $X \mapsto \mathcal{U}(0, 1)$.

Description de la méthode

- ▶ On cherche donc à calculer

$$I = \int_0^1 g(x) dx$$

- ▶ On l'écrit comme $I = E[g(X)]$: l'espérance de la variable aléatoire $g(X)$, où $X \mapsto \mathcal{U}(0, 1)$.
- ▶ Par conséquent, si on dispose d'un n -échantillon (X_1, \dots, X_n) iid de loi $\mathcal{U}(0, 1)$, on peut approximer I par l'estimateur de la **moyenne empirique** :

$$S_n = \frac{1}{n} \sum_{i=1}^n g(X_i)$$

Description de la méthode

- ▶ On cherche donc à calculer

$$I = \int_0^1 g(x) dx$$

- ▶ On l'écrit comme $I = E[g(X)]$: l'espérance de la variable aléatoire $g(X)$, où $X \mapsto \mathcal{U}(0, 1)$.
- ▶ Par conséquent, si on dispose d'un n -échantillon (X_1, \dots, X_n) iid de loi $\mathcal{U}(0, 1)$, on peut approximer I par l'estimateur de la **moyenne empirique** :

$$S_n = \frac{1}{n} \sum_{i=1}^n g(X_i)$$

\Rightarrow il suffit de savoir tirer des nombres aléatoires uniformément sur $[0, 1]$, i.e., **simuler une v.a. uniforme**.

Description de la méthode

- En pratique, on s'intéresse souvent à

$$I = \int g(x)f(x)dx,$$

où f est une densité de probabilité quelconque.

- ▶ En pratique, on s'intéresse souvent à

$$I = \int g(x)f(x)dx,$$

où f est une densité de probabilité quelconque.

- ▶ On conserve la forme générale de l'espérance et on interprète I comme

$$I = E[g(X)],$$

où X est distribuée selon f .

- ▶ En pratique, on s'intéresse souvent à

$$I = \int g(x)f(x)dx,$$

où f est une densité de probabilité quelconque.

- ▶ On conserve la forme générale de l'espérance et on interprète I comme

$$I = E[g(X)],$$

où X est distribuée selon f .

- ▶ On applique le même principe en **simulant une variable aléatoire de loi f** .

Justification de la méthode (1/2)

Deux théorèmes bien connus permettent de justifier la validité de cette méthode :

Justification de la méthode (1/2)

Deux théorèmes bien connus permettent de justifier la validité de cette méthode :

1. La loi forte des grands nombres qui nous dit que \bar{X}_n converge vers $E(X)$:

$$E(X) = \lim_{n \rightarrow +\infty} \bar{X}_n = \lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{i=1}^n X_i.$$

- ce résultat nous dit donc que l'approximation est valide.
- (NB : il faut néanmoins que $E(|X|)$ soit intégrable.)

Justification de la méthode (2/2)

Deux théorèmes bien connus permettent de justifier la validité de cette méthode :

2. Le Théorème de la Limite Centrale qui nous dit que

$$\frac{\sqrt{n}}{\sigma} \epsilon_n \rightarrow \mathcal{N}(0, 1),$$

où $\epsilon_n = E(X) - \bar{X}_n$ est l'erreur d'approximation, et $\sigma^2 = \text{var}(X)$.

Justification de la méthode (2/2)

Deux théorèmes bien connus permettent de justifier la validité de cette méthode :

2. Le Théorème de la Limite Centrale qui nous dit que

$$\frac{\sqrt{n}}{\sigma} \epsilon_n \rightarrow \mathcal{N}(0, 1),$$

où $\epsilon_n = E(X) - \bar{X}_n$ est l'erreur d'approximation, et $\sigma^2 = \text{var}(X)$.

- ce résultat quantifie la vitesse de convergence de notre estimateur :

$$\epsilon_n \rightarrow \mathcal{N}(0, \sigma/\sqrt{n}).$$

- "il converge en racine de n " : il faut 4 fois plus de réalisations pour réduire l'erreur de moitié.

Justification de la méthode (2/2)

Deux théorèmes bien connus permettent de justifier la validité de cette méthode :

2. Le Théorème de la Limite Centrale qui nous dit que

$$\frac{\sqrt{n}}{\sigma} \epsilon_n \rightarrow \mathcal{N}(0, 1),$$

où $\epsilon_n = E(X) - \bar{X}_n$ est l'erreur d'approximation, et $\sigma^2 = \text{var}(X)$.

- ce résultat quantifie la vitesse de convergence de notre estimateur :

$$\epsilon_n \rightarrow \mathcal{N}(0, \sigma/\sqrt{n}).$$

- "il converge en racine de n " : il faut 4 fois plus de réalisations pour réduire l'erreur de moitié.
- par contre il ne permet pas de borner l'erreur...

- ▶ le TLC ne nous permet pas de borner l'erreur, mais il nous permet de donner un **intervalle de confiance** :
 - ▶ Si $N \rightarrow \mathcal{N}(0, 1)$ alors $p(|N| \leq 1.96) = 0.95$.³
 - ▶ On a donc $p(|\epsilon_n| < 1.96 \frac{\sigma}{\sqrt{n}}) = 0.95$.

3. plus généralement : $p(|N| \leq t_{\alpha/2}) = 1 - \alpha$, où $t_{\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi $\mathcal{N}(0, 1)$.

- ▶ le TLC ne nous permet pas de borner l'erreur, mais il nous permet de donner un **intervalle de confiance** :

- ▶ Si $N \rightarrow \mathcal{N}(0, 1)$ alors $p(|N| \leq 1.96) = 0.95$.³

- ▶ On a donc $p(|\epsilon_n| < 1.96 \frac{\sigma}{\sqrt{n}}) = 0.95$.

⇒ l'intervalle de confiance à 95% de $E(X)$ est donc :

$$\left[\bar{X}_n - 1.96 \frac{\sigma}{\sqrt{n}} ; \bar{X}_n + 1.96 \frac{\sigma}{\sqrt{n}} \right]$$

3. plus généralement : $p(|N| \leq t_{\alpha/2}) = 1 - \alpha$, où $t_{\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi $\mathcal{N}(0, 1)$.

- ▶ le TLC ne nous permet pas de borner l'erreur, mais il nous permet de donner un **intervalle de confiance** :

- ▶ Si $N \rightarrow \mathcal{N}(0, 1)$ alors $p(|N| \leq 1.96) = 0.95$.³

- ▶ On a donc $p(|\epsilon_n| < 1.96 \frac{\sigma}{\sqrt{n}}) = 0.95$.

⇒ l'intervalle de confiance à 95% de $E(X)$ est donc :

$$\left[\bar{X}_n - 1.96 \frac{\sigma}{\sqrt{n}} ; \bar{X}_n + 1.96 \frac{\sigma}{\sqrt{n}} \right]$$

- ▶ En pratique, on ne connaît pas la variance théorique σ^2 et on l'estime par la variance empirique :

$$\bar{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

3. plus généralement : $p(|N| \leq t_{\alpha/2}) = 1 - \alpha$, où $t_{\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi $\mathcal{N}(0, 1)$.

En résumé

On cherche à calculer $I = \int g(x)f(x)dx$, où f est une densité de probabilité :

Outline

UE StatComp

Introduction

Simulation de variables aléatoires

Introduction

Inversion

Rejet

Loi uniforme

Méthodes MC pour l'intégration

Pour aller plus loin : réduction de variance

Références

En résumé

On cherche à calculer $I = \int g(x)f(x)dx$, où f est une densité de probabilité :

1. On **simule un n-échantillon** (X_1, \dots, X_n) selon la loi f .

En résumé

On cherche à calculer $I = \int g(x)f(x)dx$, où f est une densité de probabilité :

1. On **simule un n-échantillon** (X_1, \dots, X_n) selon la loi f .
2. On calcule :

$$S_n = \frac{1}{n} \sum_{i=1}^n g(X_i) \quad \text{et} \quad V_n = \frac{1}{n-1} \sum_{i=1}^n (g(X_i) - S_n)^2.$$

En résumé

On cherche à calculer $I = \int g(x)f(x)dx$, où f est une densité de probabilité :

1. On **simule un n-échantillon** (X_1, \dots, X_n) selon la loi f .
2. On calcule :

$$S_n = \frac{1}{n} \sum_{i=1}^n g(X_i) \quad \text{et} \quad V_n = \frac{1}{n-1} \sum_{i=1}^n (g(X_i) - S_n)^2.$$

3. On donne un **intervalle de confiance** sur I défini comme :

$$\left[S_n - t_{\alpha/2} \sqrt{V_n/n} ; S_n + t_{\alpha/2} \sqrt{V_n/n} \right],$$

où $t_{\alpha/2}$ est le quantile d'ordre $(1 - \alpha/2)$ de la loi $\mathcal{N}(0, 1)$, pour un intervalle de confiance à $1 - \alpha$.

- (en général on prend $\alpha = 0.05$ et $t_{\alpha/2} = 1.96$ pour un intervalle de confiance à 95%).

- ▶ Cette méthode est simple à mettre en œuvre.
 - ▶ Le seul pré-requis est de savoir **simuler des variables aléatoires** selon une loi d'intérêt.

- ▶ Cette méthode est simple à mettre en œuvre.
 - ▶ Le seul pré-requis est de savoir **simuler des variables aléatoires** selon une loi d'intérêt.
- ▶ Sa précision augmente (i.e., la largeur de l'intervalle de confiance décroît) en fonction de \sqrt{n} , **quelle que soit la dimension du problème**.
 - ▶ faible dimension : relativement lent par rapport aux méthodes déterministes.
 - ▶ haute dimension : parfois la seule approche donnant une solution dans un temps raisonnable.

- ▶ Cette méthode est simple à mettre en œuvre.
 - ▶ Le seul pré-requis est de savoir **simuler des variables aléatoires** selon une loi d'intérêt.
- ▶ Sa précision augmente (i.e., la largeur de l'intervalle de confiance décroît) en fonction de \sqrt{n} , **quelle que soit la dimension du problème**.
 - ▶ faible dimension : relativement lent par rapport aux méthodes déterministes.
 - ▶ haute dimension : parfois la seule approche donnant une solution dans un temps raisonnable.
- ▶ En pratique, elle peut être gourmande en temps de calcul à cause (1) de sa faible vitesse de convergence et (2) du coût calculatoire de g qui peut être élevé.
 - ▶ les **méthodes de réduction de variance** permettent d'accélérer la vitesse de convergence de l'algorithme.

Exemple 1

- ▶ On veut calculer $I = \int_0^1 e^{-x} dx$.
- ▶ La solution est $I = 1 - e^{-1} = 0.6321$.

Exemple 1

- ▶ On veut calculer $I = \int_0^1 e^{-x} dx$.
- ▶ La solution est $I = 1 - e^{-1} = 0.6321$.

- ▶ On peut l'approximer en R par :

```
> n = 1000          # nombre de tirages  
> x = runif(n)      # tirage selon la loi uniforme  
> gx = exp(-x)  
> I.hat = mean(gx)
```

ce qui donne⁴ 0.6307344.

Exemple 1

- ▶ On veut calculer $I = \int_0^1 e^{-x} dx$.
- ▶ La solution est $I = 1 - e^{-1} = 0.6321$.

- ▶ On peut l'approximer en R par :

```
> n = 1000          # nombre de tirages
> x = runif(n)       # tirage selon la loi uniforme
> gx = exp(-x)
> I.hat = mean(gx)
```

ce qui donne⁴ 0.6307344.

- ▶ On peut également donner un intervalle de confiance :

```
> alpha = 0.05
> a = qnorm(1-(alpha/2))
> I1 = I.hat - a*sqrt(var(gx)/n)
> I2 = I.hat + a*sqrt(var(gx)/n)
```

ce qui donne [0.6193152; 0.6421535].

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

\Rightarrow Première approche : se baser sur $\mathcal{U}(0, 1)$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Première approche : se baser sur $\mathcal{U}(0, 1)$

- Problème : il faut ramener les limites de l'intégrale à $[0, 1]$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Première approche : se baser sur $\mathcal{U}(0, 1)$

- Problème : il faut ramener les limites de l'intégrale à $[0, 1]$
- Solution = changement de variable :

$$\text{prendre } y = \frac{x - a}{b - a} \text{ soit } \begin{cases} x = (b - a)y + a \\ dx = (b - a)dy \end{cases}$$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Première approche : se baser sur $\mathcal{U}(0, 1)$

- Problème : il faut ramener les limites de l'intégrale à $[0, 1]$
- Solution = changement de variable :

$$\text{prendre } y = \frac{x - a}{b - a} \text{ soit } \begin{cases} x = (b - a)y + a \\ dx = (b - a)dy \end{cases}$$

- On a donc :

$$I = (b - a) \int_0^1 \exp((a - b)y - a) dy$$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Première approche : se baser sur $\mathcal{U}(0,1)$

- Problème : il faut ramener les limites de l'intégrale à $[0,1]$
- Solution = changement de variable :

$$\text{prendre } y = \frac{x-a}{b-a} \text{ soit } \begin{cases} x = (b-a)y + a \\ dx = (b-a)dy \end{cases}$$

- On a donc :

$$I = (b-a) \int_0^1 \exp((a-b)y - a) dy$$

- Exemple :

```
> m = 1000; a = 2; b = 4  
> y = runif(m) # tirage selon la loi uniforme(0,1)  
> Ihat.1 = (b-a)*mean( exp((a-b)*y-a) )
```

ce qui donne 0.1187561 (au lieu de 0.1170196).

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

\Rightarrow Deuxième approche : tirer dans $\mathcal{U}(a, b)$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Deuxième approche : tirer dans $\mathcal{U}(a, b)$

► Problème :

► la fonction $f(x) = \mathbf{1}(x \in [a, b])$ n'est pas une densité

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Deuxième approche : tirer dans $\mathcal{U}(a, b)$

► Problème :

- la fonction $f(x) = \mathbf{1}(x \in [a, b])$ n'est pas une densité
- la densité de la loi $\mathcal{U}(a, b)$ est $f(x) = \frac{1}{b-a} \mathbf{1}(x \in [a, b])$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Deuxième approche : tirer dans $\mathcal{U}(a, b)$

► Problème :

- la fonction $f(x) = \mathbf{1}(x \in [a, b])$ n'est pas une densité
- la densité de la loi $\mathcal{U}(a, b)$ est $f(x) = \frac{1}{b-a} \mathbf{1}(x \in [a, b])$

► Solution = faire apparaître la densité $\mathcal{U}(a, b)$:

$$\begin{aligned} I &= \int_a^b e^{-x} dx \\ &= (b-a) \int_a^b e^{-x} \frac{1}{b-a} dx \end{aligned}$$

Exemple 2 : on veut calculer $I = \int_a^b e^{-x} dx$

⇒ Deuxième approche : tirer dans $\mathcal{U}(a, b)$

► Problème :

- la fonction $f(x) = \mathbf{1}(x \in [a, b])$ n'est pas une densité
- la densité de la loi $\mathcal{U}(a, b)$ est $f(x) = \frac{1}{b-a} \mathbf{1}(x \in [a, b])$

► Solution = faire apparaître la densité $\mathcal{U}(a, b)$:

$$\begin{aligned} I &= \int_a^b e^{-x} dx \\ &= (b-a) \int_a^b e^{-x} \frac{1}{b-a} dx \end{aligned}$$


► Exemple :

```
> z = runif(m, a, b)
> Ihat.2 = (b-a) * mean( exp(-z) )
```

ce qui donne 0.1147875.

Revenons à notre exemple introductif :


- ▶ on tire aléatoirement des points (x, y) dans $[0, 1] \times [0, 1]$.
- ▶ on approxime $\pi/4$ par la proportion de points tels que $x^2 + y^2 \leq 1$.



Comment peut-on l'écrire formellement sous la forme d'un problème Monte-Carlo ?

Revenons à notre exemple introductif :

- ▶ on tire aléatoirement des points (x, y) dans $[0, 1] \times [0, 1]$.
- ▶ on approxime $\pi/4$ par la proportion de points tels que $x^2 + y^2 \leq 1$.



Comment peut-on l'écrire formellement sous la forme d'un problème Monte-Carlo ?

$$\Rightarrow \text{celui d'approximer } I = \int_0^1 \int_0^1 \mathbf{1}(x^2 + y^2 \leq 1) dx dy.$$

- ▶ Simulation de variables aléatoires :
 - ▶ méthodes par inversion et par rejet
 - ▶ place centrale de la loi $\mathcal{U}(0,1)$
 - ▶ pour aller plus loin : rejet adaptatif et échantillonnage préférentiel.

- ▶ Simulation de variables aléatoires :
 - ▶ méthodes par inversion et par rejet
 - ▶ place centrale de la loi $\mathcal{U}(0,1)$
 - ▶ pour aller plus loin : rejet adaptatif et échantillonnage préférentiel.
- ▶ Méthodes MC pour l'intégration :
 - ▶ approche stochastique à un problème déterministe
 - ▶ solution = estimation + intervalle de confiance
 - ▶ parfois la seule solution envisageable
 - ▶ e.g., en physique et en finance.
 - ▶ attention aux domaines de définition de l'intégrale et de la densité à simuler.
 - ▶ changement de variable, normalisation de la densité
 - ▶ pour aller plus loin : méthodes de réduction de variance.

Introduction

Simulation de
variables
aléatoires

Introduction

Inversion

Rejet

Loi uniforme

Méthodes MC
pour l'intégration

Pour aller plus
loin : réduction
de variance

Références

Pour aller plus loin...
méthodes de réduction de variance

Méthodes de réduction de variance

Objectif :

- ▶ Améliorer la **vitesse de convergence** de l'estimateur d'intégrale / d'espérance.
- ▶ L'estimateur MC standard fait une erreur $\epsilon \rightarrow N(0, \frac{\sigma}{\sqrt{n}})$: on cherche donc à diminuer sa variance (à n fixé).

Méthodes de réduction de variance

Outline

UE StatComp

Introduction

Simulation de
variables
aléatoires

Introduction
Inversion
Rejet
Loi uniforme

Méthodes MC
pour l'intégration

Pour aller plus
loin : réduction
de variance

Références

Objectif :

- ▶ Améliorer la **vitesse de convergence** de l'estimateur d'intégrale / d'espérance.
- ▶ L'estimateur MC standard fait une erreur $\epsilon \rightarrow N(0, \frac{\sigma}{\sqrt{n}})$: on cherche donc à diminuer sa variance (à n fixé).

Principe :

- ▶ trouver des moyens de ré-écrire $I = E[g(X)]$ comme $I = E[h(Y)]$, tels que $\text{var}(h(Y)) \leq \text{var}(g(X))$.

Méthodes de réduction de variance

Objectif :

- ▶ Améliorer la **vitesse de convergence** de l'estimateur d'intégrale / d'espérance.
- ▶ L'estimateur MC standard fait une erreur $\epsilon \rightarrow N(0, \frac{\sigma}{\sqrt{n}})$: on cherche donc à diminuer sa variance (à n fixé).

Principe :

- ▶ trouver des moyens de ré-écrire $I = E[g(X)]$ comme $I = E[h(Y)]$, tels que $\text{var}(h(Y)) \leq \text{var}(g(X))$.

Plusieurs approches :

- ▶ échantillonnage préférentiel ("importance sampling"),
- ▶ utilisation de variables antithétiques,
- ▶ utilisation de variables de contrôle,
- ▶ (stratification).

Principe :

- Introduire une **nouvelle densité** \tilde{f} , et ré-écrire l'intégrale :

$$I = \int g(x)f(x)dx = \int \frac{g(x)f(x)}{\tilde{f}(x)}\tilde{f}(x)dx.$$

Introduction

Simulation de
variables
aléatoires

Introduction

Inversion

Rejet

Loi uniforme

Méthodes MC
pour l'intégrationPour aller plus
loin : réduction
de variance

Références

Principe :

- Introduire une **nouvelle densité** \tilde{f} , et ré-écrire l'intégrale :

$$I = \int g(x)f(x)dx = \int \frac{g(x)f(x)}{\tilde{f}(x)}\tilde{f}(x)dx.$$

- On a donc $E[g(X)] = E[\frac{g(Y)f(Y)}{\tilde{f}(Y)}]$, où X est distribuée selon f et Y est distribuée selon \tilde{f} .

\Rightarrow Nouveau schéma avantageux si $var(\frac{g(Y)f(Y)}{\tilde{f}(Y)}) < var(g(X))$.

Introduction

Simulation de
variables
aléatoires

Introduction

Inversion

Rejet

Loi uniforme

Méthodes MC
pour l'intégrationPour aller plus
loin : réduction
de variance

Références

Principe :

- ▶ Introduire une **nouvelle densité \tilde{f}** , et ré-écrire l'intégrale :

$$I = \int g(x)f(x)dx = \int \frac{g(x)f(x)}{\tilde{f}(x)}\tilde{f}(x)dx.$$

- ▶ On a donc $E[g(X)] = E[\frac{g(Y)f(Y)}{\tilde{f}(Y)}]$, où X est distribuée selon f et Y est distribuée selon \tilde{f} .

\Rightarrow Nouveau schéma avantageux si $var(\frac{g(Y)f(Y)}{\tilde{f}(Y)}) < var(g(X))$.

En pratique :

- ▶ Il faut choisir **une densité \tilde{f}** proche de $|g \times f|$.
- ▶ Il faut savoir selon **simuler selon \tilde{f}** .
- ▶ \tilde{f} s'appelle la **fonction d'importance**.

Réduction de variance par variables antithétiques

Principe :

- Pour approximer $I = \int_0^1 g(x)dx$ utiliser le fait que si $U \rightarrow \mathcal{U}(0,1)$, alors $(1 - U) \rightarrow \mathcal{U}(0,1)$.

Réduction de variance par variables antithétiques

Principe :

- Pour approximer $I = \int_0^1 g(x)dx$ utiliser le fait que si $U \rightarrow \mathcal{U}(0, 1)$, alors $(1 - U) \rightarrow \mathcal{U}(0, 1)$.
- On peut donc estimer $I = E[g(U)]$ à n fixé par :

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \quad \text{ou} \quad \frac{1}{n} \sum_{i=1}^{n/2} \left(g(X_i) + g(1 - X_i) \right).$$

Réduction de variance par variables antithétiques

Principe :

- Pour approximer $I = \int_0^1 g(x)dx$ utiliser le fait que si $U \rightarrow \mathcal{U}(0, 1)$, alors $(1 - U) \rightarrow \mathcal{U}(0, 1)$.
- On peut donc estimer $I = E[g(U)]$ à n fixé par :

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \quad \text{ou} \quad \frac{1}{n} \sum_{i=1}^{n/2} \left(g(X_i) + g(1 - X_i) \right).$$

\Rightarrow Nouveau schéma toujours plus efficace si g est monotone, car $g(U)$ et $g(1 - U)$ sont alors anti-corrélées.

- et $\text{var}(A + B) = \text{var}(A) + \text{var}(B) + 2\text{cov}(A, B)$

Réduction de variance par variables antithétiques

Principe :

- Pour approximer $I = \int_0^1 g(x)dx$ utiliser le fait que si $U \rightarrow \mathcal{U}(0,1)$, alors $(1-U) \rightarrow \mathcal{U}(0,1)$.
- On peut donc estimer $I = E[g(U)]$ à n fixé par :

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \quad \text{ou} \quad \frac{1}{n} \sum_{i=1}^{n/2} \left(g(X_i) + g(1 - X_i) \right).$$

\Rightarrow Nouveau schéma toujours plus efficace si g est monotone, car $g(U)$ et $g(1-U)$ sont alors anti-corrélées.

- et $\text{var}(A+B) = \text{var}(A) + \text{var}(B) + 2\text{cov}(A, B)$

En pratique :

- n'est valable que si g est continue et monotone.
- U et $(1-U)$ sont dites antithétiques.

Réduction de variance par variables de contrôle

Principe :

- ▶ Pour approximer $I = \int g(x)dx$, introduire une fonction h proche de g qui soit facilement intégrable.
- ▶ On peut alors écrire :

$$I = E[g(X)] = E[g(X) - h(X)] + E[h(X)]$$

⇒ Nouveau schéma avantageux si $\text{var}(g(X) - h(X)) < \text{var}(g(X))$

Réduction de variance par variables de contrôle

Principe :

- ▶ Pour approximer $I = \int g(x)dx$, introduire une **fonction h proche de g** qui soit **facilement intégrable**.
- ▶ On peut alors écrire :

$$I = E[g(X)] = E[g(X) - h(X)] + E[h(X)]$$

⇒ Nouveau schéma avantageux si $\text{var}(g(X) - h(X)) < \text{var}(g(X))$

En pratique :

- ▶ Il faut donc trouver h qui soit **proche de g** et que l'on sache **intégrer** (i.e., que l'on sache calculer $E[h(X)]$).
- ▶ Le fait que h et g soient corrélées devrait garantir que $\text{var}(g(X) - h(X))$ soit faible.
- ▶ $h(X)$ est la **variable de contrôle** de $g(X)$.

Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

Maria L. Rizzo. *Statistical Computing with R*. CRC Press, 2007.