

Introduction à l'analyse bayésienne

Franck Corset

Master 2 - SSD

Principes de l'inférence bayésienne



Figure 1: Sir Thomas Bayes

Rappels : Modèle classique - Analyse fréquentiste (1/3)

- ▶ On se place dans un espace probabilisé paramétrique $(\mathcal{X}, \mathcal{B}, P_\theta)$ où $\theta \in \Theta$ est le vecteur des paramètres du modèle, \mathcal{X} est l'espace des données et Θ est l'espace des paramètres.
- ▶ Le but de l'analyse statistique est de faire l'inférence sur le paramètre θ . Si on considère que le modèle est dominé par une mesure μ si P_θ admet une densité par rapport à μ :

$$f(X|\theta) = \frac{dP_\theta}{d\mu}$$

Rappels : Modèle classique - Analyse fréquentiste (2/3)

- ▶ Cette fonction, notée $\ell(\theta) = f(X|\theta)$, vue comme une fonction de θ , une fois qu'on a observé un tirage de X , est appelée vraisemblance du modèle. C'est la loi conditionnelle de X conditionnellement à θ .
- ▶ A partir de cette équation, il est possible de calculer l'estimateur du maximum de vraisemblance (EMV ou MLE en anglais), noté $\hat{\theta}_{ML}$, valeur qui maximise la fonction de vraisemblance.

Rappels : Modèle classique - Analyse fréquentiste (3/3)

- ▶ Ainsi, si l'on se place dans le cadre d'un échantillon i.i.d, (X_1, \dots, X_n) de même loi que X , ayant pour densité $f(x|\theta)$, où θ est paramètre inconnu que l'on cherche à estimer.
- ▶ Sachant que l'on a observé un échantillon (x_1, \dots, x_n) , vu comme la réalisation de l'échantillon i.i.d. (X_1, \dots, X_n) , la fonction de vraisemblance s'écrit

$$L(\theta|(x_1, \dots, x_n)) = \prod_{i=1}^n f(x_i|\theta) \quad (1)$$

Analyse bayésienne

Introduction

- ▶ On va ici considérer que le paramètre θ est aléatoire.
- ▶ L'espace des paramètres Θ est muni d'une probabilité π tel que $(\Theta, \mathcal{A}, \pi)$ soit un espace probabilisé.
- ▶ On note $\theta \sim \pi$.
- ▶ π est appelé loi a priori. Cette loi détermine l'information a priori que l'on a sur le phénomène étudié, c'est-à-dire avant d'avoir observé X .
- ▶ Généralement, cette loi dépend elle-même de paramètres. Ces paramètres sont appelés hyperparamètres du modèle.

Loi jointe et loi a posteriori

- ▶ La loi jointe (X, θ) s'écrit

$$\lambda(X, \theta) = f(X|\theta)d\pi(\theta) = f(X|\theta)\pi(\theta)d\nu$$

où ν est la mesure de Lebesgue.

- ▶ La loi a posteriori est définie par sa densité

$$d\pi(\theta|X) = \frac{f(X|\theta)d\pi(\theta)}{\int_{\Theta} f(X|\theta)d\pi(\theta)}$$

- ▶ La quantité $m(X) = \int_{\Theta} f(X|\theta)d\pi(\theta)$ est la loi marginale de X et est une constante de normalisation de la loi a posteriori, indépendante de θ .
- ▶ Par la suite, on notera $\pi(\theta|X) \propto f(X|\theta)\pi(\theta)$

Exemple : Cas gaussien (1/4)

- ▶ On suppose que $X \sim \mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.
- ▶ On cherche à inférer sur $\theta = \mu$
- ▶ On suppose que la loi a priori sur μ est $\pi(\mu) = \mathcal{N}(\mu_0, \tau^2)$
- ▶ μ_0 et τ^2 sont appelés hyperparamètres du modèle

Exemple : Cas gaussien (2/4)

- ▶ On suppose que l'on dispose d'un échantillon i.i.d. (x_1, \dots, x_n) , réalisation de (X_1, \dots, X_n)
- ▶ La vraisemblance du modèle est

$$l(\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

- ▶ L'estimation par maximum de vraisemblance donne

$$\hat{\mu} = \bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

Exemple : Cas gaussien (3/4)

- La loi a posteriori $\pi(\mu|(x_1, \dots, x_n))$ est

$$\frac{\frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} \frac{1}{\sqrt{2\pi\tau^2}} e^{-\frac{1}{2\tau^2} (\mu - \mu_0)^2}}{C}$$

où C est la constante de normalisation.

- En ne gardant que les termes dépendants de μ , on a

$$\begin{aligned} \pi(\mu|(x_1, \dots, x_n)) &\propto \exp\left(-\frac{n\mu^2}{2\sigma^2} - \frac{\mu^2}{2\tau^2} + \frac{\mu \sum_i x_i}{\sigma^2} + \frac{\mu\mu_0}{\tau^2}\right) \\ &\propto \exp\left(-\frac{1}{2\frac{\sigma^2\tau^2}{n\tau^2 + \sigma^2}} \left[\mu - \left(\frac{n\tau^2}{n\tau^2 + \sigma^2} \bar{x}_n + \frac{n\tau^2}{n\tau^2 + \sigma^2} \mu_0\right)\right]^2\right) \end{aligned}$$

Exemple : Cas gaussien (4/4)

- ▶ La loi a posteriori est

$$\mathcal{N}\left(\frac{n\tau^2}{n\tau^2 + \sigma^2}\bar{x}_n + \frac{\sigma^2}{n\tau^2 + \sigma^2}\mu_0, \frac{\sigma^2\tau^2}{n\tau^2 + \sigma^2}\right)$$

- ▶ L'espérance est une combinaison convexe de la moyenne empirique et de la moyenne a priori
- ▶ Quand $n \rightarrow +\infty$, l'espérance tend vers \bar{x}_n (et donc vers l'estimation par maximum de vraisemblance) et la variance vers 0.
- ▶ Plus on possède de données, moins l'a priori est influent !

Exemple 2 : Cas Bernoulli (1/3)

- ▶ On note θ la probabilité qu'un patient soit guéri à l'issu d'un traitement. Pour estimer ce paramètre, on dispose d'un échantillon de n patients. On note $x_i \in \{0, 1\}$, l'état du patient après avoir subi le traitement ($x_i = 1$ si le patient est guéri et $x_i = 0$ sinon).
- ▶ On suppose que l'échantillon (x_1, \dots, x_n) est la réalisation d'un échantillon i.i.d de n variables aléatoires.
- ▶ On suppose que X_i suit une loi de Bernoulli de paramètre θ
- ▶ La vraisemblance s'écrit

$$\ell(\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^s (1 - \theta)^{n-s}$$

$$\text{où } s = \sum_{i=1}^n x_i.$$

Exemple 2 : Cas Bernoulli (2/3)

- L'estimation par maximum de vraisemblance est

$$\hat{\theta} = \frac{s}{n} = \bar{x}_n$$

- Comme $\theta \in [0, 1]$, on propose la loi Beta, notée $\pi(\theta) = \mathcal{B}(a, b)$ de densité

$$\pi(\theta) = \frac{1}{B(a, b)} \theta^{a-1} (1 - \theta)^{b-1}$$

$$\text{où } B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} \text{ et } \Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$$

Exemple 2 : Cas Bernoulli (3/3)

- La loi a posteriori est donc

$$\pi(\theta|(x_1, \dots, x_n)) = \frac{\theta^{s+a-1}(1-\theta)^{n-s+b-1}}{\int_0^1 \theta^{s+a-1}(1-\theta)^{n-s+b-1} d\theta}$$

- La loi a posteriori est donc une loi Beta :

$$\theta|(x_1, \dots, x_n) \sim \mathcal{B}(a + \sum_{i=1}^n x_i, n - \sum_{i=1}^n x_i + b)$$

Exercice

- ▶ Soit le modèle statistique bayésien suivant : $X_i \sim \mathcal{P}(\theta)$ et $\theta \sim \text{Gamma}(a, b)$. Déterminer la loi a posteriori.
- ▶ La loi de Poisson de paramètre θ est

$$\forall k \in \mathbb{N}, P(X = k) = \frac{\theta^k}{k!} e^{-\theta}$$

- ▶ La loi $\text{Gamma}(a, b)$ est caractérisée par sa densité :

$$f(x) = \frac{x^{a-1} e^{-x/b}}{\Gamma(a) b^a}$$

Application et illustration en R

- ▶ Mettre en oeuvre ces deux situations dans le logiciel R.
- ▶ Faire varier les différents paramètres des modèles.
- ▶ Comparer les lois a posteriori et les lois a priori sur un même graphique.