

Estimation bayésienne

Franck Corset

Master 2 - SSD

Estimation bayésienne

Définition

Cas uni-dimensionnel

- ▶ On suppose que θ est réel et $\mathbf{x} = (x_1, \dots, x_n)$ sont l'échantillon observé.
- ▶ On note $\pi(\theta|\mathbf{x})$, la loi a posteriori.
- ▶ On appelle estimation bayésienne de θ la moyenne a posteriori, notée $\mathbb{E}[\theta|\mathbf{x}]$.
- ▶ Cette moyenne a posteriori est

$$\mathbb{E}[\theta|(x_1, \dots, x_n)] = \int_{\Theta} \theta \pi(\theta|\mathbf{x}) d\theta = \frac{\int_{\Theta} \theta f(\mathbf{x}|\theta) \pi(\theta) d\theta}{\int_{\Theta} f(\mathbf{x}|\theta) \pi(\theta) d\theta}$$

- ▶ On note $\hat{\theta}_B$, l'estimateur bayésien.

Exemple 1 : Cas Gaussien

- ▶ $X \sim \mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.
- ▶ Loi a priori sur μ est $\pi(\mu) = \mathcal{N}(\mu_0, \tau^2)$
- ▶ La loi a posteriori est

$$\mathcal{N}\left(\frac{n\tau^2}{n\tau^2 + \sigma^2}\bar{x}_n + \frac{\sigma^2}{n\tau^2 + \sigma^2}\mu_0, \frac{\sigma^2\tau^2}{n\tau^2 + \sigma^2}\right)$$

- ▶ L'estimateur bayésien est

$$\hat{\theta}_B = \frac{n\tau^2}{n\tau^2 + \sigma^2}\bar{x}_n + \frac{\sigma^2}{n\tau^2 + \sigma^2}\mu_0$$

Exemple 2 : Cas Bernoulli

- ▶ X suit une loi de Bernoulli de paramètre θ
- ▶ Loi a priori : loi Beta, notée $\pi(\theta) = \mathcal{B}(a, b)$ de densité

$$\pi(\theta) = \frac{1}{B(a, b)} \theta^{a-1} (1 - \theta)^{b-1}$$

où $B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$ et $\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$

- ▶ La loi a posteriori est une loi Beta :

$$\theta | (x_1, \dots, x_n) \sim \mathcal{B}(a + \sum_{i=1}^n x_i, n - \sum_{i=1}^n x_i + b)$$

- ▶ L'estimateur bayésien est :

$$\hat{\theta}_B = \frac{a + \sum_{i=1}^n x_i}{a + b + n}$$

Remarques

- ▶ Si l'on pense que la vraisemblance possède plusieurs maxima locaux, on peut choisir le mode a posteriori comme estimateur bayésien :

$$\hat{\theta}_B = \operatorname{argmax}_{\theta \in \Theta} \pi(\theta|\mathbf{x})$$

- ▶ Dans notre cas, on ne prendra que la moyenne a posteriori comme estimateur bayésien.
- ▶ L'estimation bayésienne d'une fonction $h(\theta)$ est $\mathbb{E}[h(\theta)|\mathbf{x}]$, où l'espérance est définie à partir de la loi a posteriori de θ .

Exemple 3 : Cas Poisson

- ▶ $X \sim \mathcal{P}(\theta)$ et la loi a priori est $\theta \sim \text{Gamma}(a, b)$.
- ▶ La loi a posteriori $\pi(\theta)$ est la loi $\text{Gamma}(a + \sum_{i=1}^n x_i, \frac{b}{bn + 1})$
- ▶ L'estimateur bayésien est donc

$$\hat{\theta}_B = \left(\frac{a}{n} + \bar{x}_n \right) \frac{bn}{bn + 1}$$

Remarques

- ▶ Dans la plupart des exemples précédents, les lois a posteriori sont de la même nature que les lois a priori : On parle de lois a priori conjuguées.
- ▶ Exemple : Soit $X \sim \mathcal{E}(\lambda)$. Montrer que la loi Gamma est une loi a priori conjuguée.
- ▶ Les lois a priori étaient toutes informatives. On se propose dans la suite de définir des lois a priori non informatives (par exemple une loi uniforme pour le cas Bernoulli)

Loi a priori impropre

- ▶ Soit $\pi(\theta)$ une fonction positive telle que $\int_{\Theta} \pi(\theta) d\theta = +\infty$
- ▶ On parle de loi impropre, mais on suppose que $m(\mathbf{x}) = \int_{\Theta} L(\theta; \mathbf{x}) \pi(\theta) d\theta$ est convergente.
- ▶ On considère alors la loi a posteriori

$$\pi(\theta|\mathbf{x}) = \frac{L(\theta; \mathbf{x})\pi(\theta)}{\int_{\Theta} L(\theta; \mathbf{x})\pi(\theta) d\theta}$$

- ▶ L'estimateur de Bayes est alors la moyenne a posteriori

$$\hat{\theta}_B = \int_{\Theta} \theta \pi(\theta|\mathbf{x}) d\theta$$

Exemple 1 (1/3)

- ▶ On suppose que $X \sim \mathcal{B}(\theta)$ et on considère la loi impropre suivante sur $]0, 1[$:

$$\pi(\theta) = \frac{1}{\theta(1 - \theta)}$$

- ▶ Calculer l'estimateur de Bayes. A quelle condition est-il défini ?
- ▶ Le comparer à l'estimateur du maximum de vraisemblance.

Exemple 1 (2/3)

- Soit $s = \sum_{i=1}^n x_i$, la vraisemblance s'écrit

$$L(\mathbf{x}; \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^s (1 - \theta)^{n-s}$$

- L'intégrale $\int_0^1 \theta^{s-1} (1 - \theta)^{n-s-1} d\theta$ converge ssi $1 - s < 1$ et $s + 1 - n < 1$, c'est-à-dire $0 < s < n$.
- La loi a posteriori est

$$\pi(\theta|\mathbf{x}) \propto \theta^{s-1} (1 - \theta)^{n-s-1}$$

Exemple 1 (3/3)

- ▶ La loi a posteriori est donc une loi Beta, $\mathcal{B}(s, n - s)$
- ▶ L'estimateur bayésien est la moyenne a posteriori

$$\hat{\theta}_B = \frac{s}{s + n - s} = \bar{x}_n = \hat{\theta}_{MLE}$$

Exemple 2 (1/3)

- ▶ On considère $X \sim \mathcal{N}(\theta, 1)$ et on considère la loi impropre suivante sur \mathbb{R} : $\pi(\theta) = 1$
- ▶ Calculer l'estimateur de Bayes. A quelle condition est-il défini ?
- ▶ Le comparer à l'estimateur du maximum de vraisemblance.

Exemple 2 (2/3)

- La vraisemblance s'écrit

$$\begin{aligned} L(\mathbf{x}; \theta) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x_i - \theta)^2\right) \\ &= \left(\frac{1}{2\pi}\right)^{n/2} \exp\left(-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2\right) \end{aligned}$$

- L'estimation par maximum de vraisemblance est $\hat{\theta}_{MLE} = \bar{x}_n$
- L'intégrale $\int_{\mathbb{R}} L(\mathbf{x}; \theta) d\theta$ est toujours convergente
- La loi a posteriori est (avec $s = \sum_{i=1}^n x_i$)

$$\pi(\theta|\mathbf{x}) \propto \exp\left(-\frac{1}{2}(n\theta^2 - 2s\theta)\right)$$

Exemple 2 (3/3)

- ▶ La loi a posteriori est $\mathcal{N}(\bar{x}_n; 1/n)$
- ▶ L'estimateur bayésien est la moyenne a posteriori :

$$\hat{\theta}_B = \bar{x}_n = \hat{\theta}_{MLE}$$

Loi a priori non informative de Jeffreys

- ▶ Soit $\theta \in \mathbb{R}$. On appelle loi de Jeffreys, la loi (éventuellement impropre) de densité à support sur Θ :

$$\pi_J(\theta) \propto (I(\theta))^{1/2}$$

où $I(\theta)$ est l'information de Fisher.

- ▶ L'information de Fisher est définie de la façon suivante

$$I(\theta) = E\left[-\frac{\partial^2}{\partial \theta^2} \log(L(X; \theta)) \mid \theta\right]$$

où $L(X; \theta)$ est la fonction de vraisemblance.

- ▶ Cette quantité représente la quantité d'information sur θ apportée par X .

Exemple : Bernoulli de paramètre θ

- ▶ On suppose que $X_i \sim \mathcal{B}(\theta)$.
- ▶ La dérivée seconde est égale à

$$\frac{\partial^2}{\partial \theta^2} \log(L(X; \theta)) = -\frac{X}{\theta^2} - \frac{n - X}{(1 - \theta)^2}$$

où $X = \sum_{i=1}^n X_i$ suit une loi binomiale, notée $\mathcal{B}(n, \theta)$.

- ▶ $l(\theta) = \frac{n}{\theta} + \frac{n}{(1 - \theta)} \propto \frac{1}{\theta(1 - \theta)}$.
- ▶ La loi de Jeffreys est donc $\pi(\theta) = (\theta(1 - \theta))^{-1/2}$, c'est-à-dire une loi Beta, $\text{Beta}(1/2, 1/2)$.

Intervalle de crédibilité

- On se place dans un cadre bayésien et on suppose que $\theta \in \mathbb{R}$.

Définition

Soit $\alpha \in]0, 1[$. Un intervalle de crédibilité I de niveau de confiance $1 - \alpha$ est défini par

$$P(\theta \in I | \mathbf{x}) = \int_I \pi(\theta | \mathbf{x}) d\theta$$

Exemple 1 : Bernoulli

- ▶ On suppose que pour tout i , $X_i \sim B(\theta)$ et que la loi a priori est : $\theta \sim U_{[0,1]}$
- ▶ On suppose que l'on a observé 20 succès parmi 60 essais
- ▶ La loi a posteriori est une loi Beta, $Beta(s + 1, n - s + 1)$
- ▶ L'intervalle de crédibilité avec un niveau de confiance de 95% (risque de 5%) est

$$P(Beta(s + 1, n - s + 1) \in [q_{0.025}; q_{0.975}]) = 0.95$$

où $q_{0.025}$ et $q_{0.975}$ sont respectivement les quantiles de la loi $Beta(s + 1, n - s + 1)$ d'ordre 0.025 et 0.975.

Application en R

```
s<-20;n<-60;moy.a.post<-(s+1)/(n+2)
```

```
moy.a.post
```

```
## [1] 0.3387097
```

```
borne.inf<-qbeta(0.025,s+1,n-s+1)
```

```
borne.sup<-qbeta(0.975,s+1,n-s+1)
```

```
int<-c(borne.inf,borne.sup)
```

```
int
```

```
## [1] 0.2272576 0.4600191
```

Exemple 2 : Normale

- ▶ On suppose que pour tout i , $X_i \sim \mathcal{N}(\theta, 1)$ et que la loi a priori est : $\pi(\theta) = 1$
- ▶ La loi a posteriori est une loi Normale, $\mathcal{N}(\bar{x}_n, 1/n)$
- ▶ L'intervalle de crédibilité avec un niveau de confiance de 95% (risque de 5%) est

$$P(\hat{\theta}_B \in [q_{0.025}; q_{0.975}]) = 0.95$$

où $q_{0.025}$ et $q_{0.975}$ sont respectivement les quantiles de la loi $\mathcal{N}(\bar{x}_n, 1/n)$ d'ordre 0.025 et 0.975.

- ▶ A comparer avec l'intervalle de confiance classique :
 $[\bar{x}_n - 1.96/\sqrt{n}; \bar{x}_n + 1.96/\sqrt{n}]$

Application en R

```
theta<-2;n<-40;  
ech<-rnorm(n,theta,1)  
moy.a.post<-mean(ech)  
borne.inf<-qnorm(0.025,mean(ech),sqrt(1/n))  
borne.sup<-qnorm(0.975,mean(ech),sqrt(1/n))  
int<-c(borne.inf,borne.sup)  
int
```

```
## [1] 1.702825 2.322620
```