

# Estimation bayésienne

Franck Corset

Master 2 - SSD

# Définition

## Cas multi-dimensionnel

- ▶ On suppose que  $\theta \in \mathbb{R}^d$  avec  $d > 1$  et que  $\mathbf{x} = (x_1, \dots, x_n)$  est l'échantillon observé.
- ▶ On va supposer que les lois a priori sont indépendantes.
- ▶ On appelle estimation bayésienne de  $\theta$  la moyenne a posteriori, notée  $\mathbb{E}[\theta|\mathbf{x}]$ .
- ▶ Cette moyenne a posteriori est

$$\mathbb{E}[\theta|(x_1, \dots, x_n)] = \int_{\Theta} \theta \pi(\theta|\mathbf{x}) d\theta = \frac{\int_{\Theta} \theta f(\mathbf{x}|\theta) \pi(\theta) d\theta}{\int_{\Theta} f(\mathbf{x}|\theta) \pi(\theta) d\theta}$$

- ▶ On note  $\hat{\theta}_B$ , l'estimateur bayésien.

## Exemple 1 : Cas Gaussien

- ▶  $X \sim \mathcal{N}(\mu, \sigma^2)$  avec  $\theta = (\mu, \sigma^2)$  inconnue.
- ▶ Loi a priori de  $\mu$  est  $\pi(\mu) = \mathcal{N}(\mu_0, \sigma_0^2)$
- ▶ Loi a priori sur  $\sigma^2$  est une inverse gamma  $\pi(\sigma^2) = IG(a, b)$  de densité

$$f(x) = \frac{b^a}{\Gamma(a)} (1/x)^{a+1} \exp(-b/x)$$

- ▶ Ainsi, la loi a priori  $\pi(\mu, \sigma^2) = \pi(\mu)\pi(\sigma^2)$ .

## Exemple 1 : Cas Gaussien

- Loi a posteriori conditionnelle de  $\mu$  sachant  $\sigma^2$  :

$$\mathcal{N}\left(\frac{n\sigma_0^2\bar{x}_n + \sigma^2\mu_0}{n\sigma_0^2 + \sigma^2}, \frac{\sigma^2\sigma_0^2}{n\sigma_0^2 + \sigma^2}\right)$$

- La loi a posteriori conditionnelle de  $\sigma^2$  sachant  $\mu$  :

$$\pi(\sigma^2|\mathbf{x}) = IG(a + n/2, b + \frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2)$$

# Algorithme de Gibbs

- Pour  $\theta = (\theta_1, \dots, \theta_p)$ , on veut simuler  $\pi(\theta)$  à partir de  $\pi_i(\theta_i | \theta_{-i})$  pour tout  $i$ .
- On initialise avec  $\theta^{(0)}$  et à l'étape  $k$ , on a :

$$\begin{aligned}(\theta_1^{(k)} | \theta^{(k-1)}) &\sim \pi_1(\theta_1^{(k)} | \theta_{-1}^{(k-1)}) \\ (\theta_2^{(k)} | \theta^{(k-1)}, \theta_1^{(k)}) &\sim \pi_2(\theta_2^{(k)} | \theta_1^{(k)}, \theta_3^{(k-1)}, \dots, \theta_p^{(k-1)}) \\ &\vdots \sim \vdots \\ (\theta_p^{(k)} | \theta_{-p}^{(k)}) &\sim \pi_p(\theta_p^{(k)} | \theta_{-p}^{(k)})\end{aligned}$$

- On génère ainsi une chaîne de Markov dont la loi stationnaire est  $\pi$ .

# Algorithme de Gibbs (exemple pour le cas gaussien)

- ▶ On initialise en choisissant un couple  $(\mu^{(0)}, (\sigma^2)^{(0)})$
- ▶ A l'étape  $k$ , on simule  $\mu^{(k)}$  selon la loi a posteriori conditionnelle  $\pi(\mu | (\sigma^2)^{(k-1)}, \mathbf{x})$  :

$$\mathcal{N}\left(\frac{n\sigma_0^2\bar{x}_n + (\sigma^2)^{(k-1)}\mu_0}{n\sigma_0^2 + (\sigma^2)^{(k-1)}}, \frac{(\sigma^2)^{(k-1)}\sigma_0^2}{n\sigma_0^2 + (\sigma^2)^{(k-1)}}\right)$$

- ▶ puis on simule  $(\sigma^2)^{(k)}$  selon la loi conditionnelle  $\pi(\sigma^2 | \mu^{(k)}, \mathbf{x})$  :

$$IG(a + n/2, b + \frac{1}{2} \sum_{i=1}^n (x_i - \mu^{(k)})^2)$$

- On s'arrête après un grand nombre d'itérations  $K$ .
- L'échantillon produit suit alors la loi a posteriori voulue.

# Algorithme de Metropolis Hasting

- ▶ On se donne une valeur initiale  $\theta^{(0)}$  puis à l'étape  $k$  : On simule  $\theta^{(k)}$  en tirant  $\theta'$  à l'aide d'une distribution instrumentale, notée  $q(\cdot|\theta^{(k-1)})$  et on choisit :

$$\begin{aligned}\theta^{(k)} &= \theta' \text{ avec une probabilité } \alpha \\ &= \theta^{(k-1)} \text{ avec une probabilité } 1 - \alpha\end{aligned}$$

$$\text{où } \alpha = \min\left(\frac{\pi(\theta')}{\pi(\theta^{(k-1)})} \frac{q(\theta^{(k-1)}|\theta')}{q(\theta'|\theta^{(k-1)})}, 1\right).$$

- ▶ Pour la loi instrumentale, on choisira souvent une loi symétrique, par exemple la loi normale centrée en  $\theta^{(k-1)}$  à l'étape  $k$ , ce qui revient à prendre  $\alpha = \min\left(\frac{\pi(\theta')}{\pi(\theta^{(k-1)})}, 1\right)$ , c'est-à-dire vu comme le rapport des lois a posteriori entre le candidat ( $\theta'$ ) et l'ancienne valeur ( $\theta^{(k-1)}$ ).